

Universidade Federal de Sergipe
Engenharia de Software II

Diagnóstico e Auditoria do Projeto LangExtract
Atividade 3 – Etapa 1

Membros:

José Fernando Bispo dos Santos – 202200014210

Valter Fabricio dos Santos – 202000066991

Raphael Ferreira Portella Bacelar - 202100045822

Professor: Dr. Glauco de Figueiredo Carneiro
Janeiro de 2026

SUMÁRIO

1. INTRODUÇÃO.....	4
2. DESCRIÇÃO DO PROJETO AVALIADO.....	4
3. METODOLOGIA DE INVESTIGAÇÃO.....	4
4. FERRAMENTAS DE CI/CD UTILIZADAS.....	5
5. EVIDÊNCIAS TÉCNICAS.....	5
6. FLUXO ATUAL.....	8
7. CONCLUSÃO.....	8

1. INTRODUÇÃO

A evolução contínua de sistemas de software exige mecanismos que garantam a qualidade e a estabilidade do código ao longo do tempo. Nesse contexto, a Integração Contínua (Continuous Integration – CI) surge como uma prática fundamental, permitindo que alterações no código sejam verificadas automaticamente, reduzindo riscos de regressão e facilitando a colaboração entre desenvolvedores.

Esta atividade tem como objetivo analisar a maturidade das práticas de CI de um projeto de software open source real, no qual a equipe atua como engenheiros de DevOps. A partir dessa análise, busca-se compreender como a automação influencia a manutenibilidade do sistema e a entrada de novos contribuidores no projeto.

2. DESCRIÇÃO DO PROJETO AVALIADO

O projeto analisado nesta atividade é o **LangExtract**, um projeto open source mantido pela Google e disponibilizado na plataforma GitHub.

Repositório: <https://github.com/google/langextract>

LangExtract é uma biblioteca Python que utiliza LLMs para extrair informações estruturadas de documentos de texto não estruturados com base em instruções definidas pelo usuário. Ela processa materiais como anotações clínicas ou relatórios, identificando e organizando detalhes-chave, ao mesmo tempo em que garante que os dados extraídos correspondam ao texto de origem.

3. METODOLOGIA DE INVESTIGAÇÃO

A investigação do projeto foi realizada por meio de uma análise exploratória do repositório no GitHub, com foco nas práticas de Integração Contínua adotadas. Foram observados os seguintes aspectos:

- Existência do diretório `.github/workflows/`;
- Análise dos arquivos YAML de workflows;
- Verificação da aba *Actions* do GitHub;

- Observação do histórico de Pull Requests

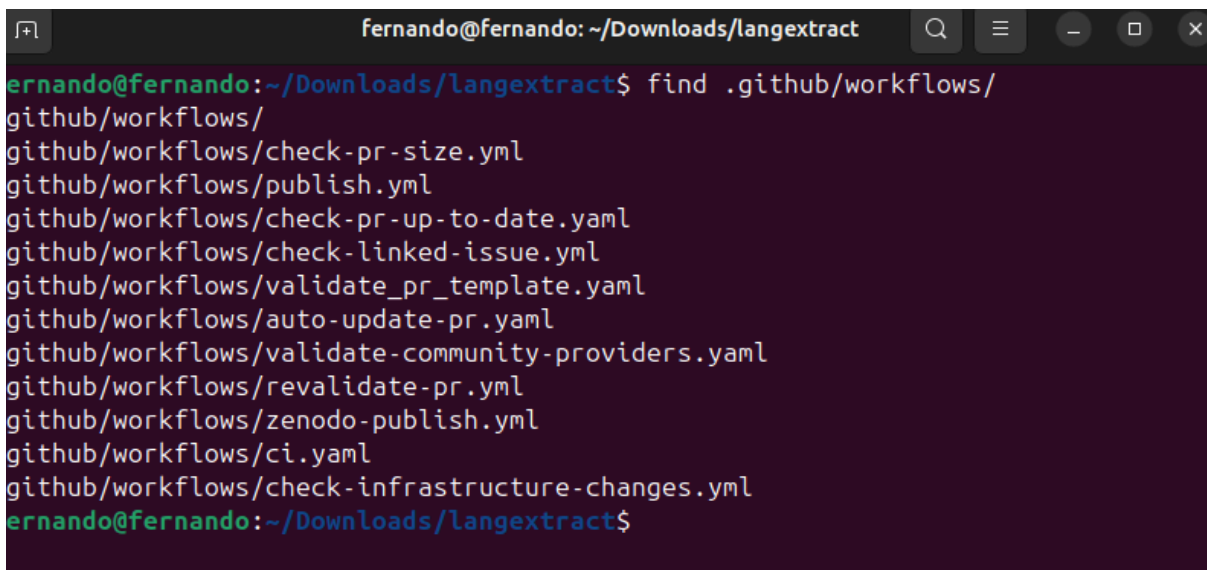
Essa abordagem permitiu mapear o fluxo atual de desenvolvimento e identificar o nível de automação presente no projeto.

4. FERRAMENTAS DE CI/CD UTILIZADAS

O projeto **LangExtract** utiliza o **GitHub Actions** como ferramenta de **Integração Contínua (CI)**. Essa ferramenta é nativa da plataforma GitHub e permite a execução automática de tarefas em resposta a eventos como *push* e *pull request*.

5. EVIDÊNCIAS TÉCNICAS

Como evidência da utilização de CI, foram identificados diversos arquivos de workflow no diretório `.github/workflows/`. Esses arquivos definem ações automatizadas que são executadas durante o ciclo de desenvolvimento do projeto.




```
fernando@fernando: ~/Downloads/langextract
fernando@fernando:~/Downloads/langextract$ find .github/workflows/
.github/workflows/
.github/workflows/check-pr-size.yml
.github/workflows/publish.yml
.github/workflows/check-pr-up-to-date.yml
.github/workflows/check-linked-issue.yml
.github/workflows/validate_pr_template.yml
.github/workflows/auto-update-pr.yml
.github/workflows/validate-community-providers.yml
.github/workflows/revalidate-pr.yml
.github/workflows/zenodo-publish.yml
.github/workflows/ci.yml
.github/workflows/check-infrastructure-changes.yml
fernando@fernando:~/Downloads/langextract$
```

Complementarmente, foi realizada uma análise do histórico de commits, . Essa verificação permitiu identificar o primeiro commit diretamente relacionado à criação e evolução dos workflows de CI. O commit 6d336c1, no qual foi adicionada uma pipeline de GitHub Actions voltada para a execução de linting e testes automatizados, com suporte a múltiplas versões

do Python (3.10 e 3.11), além da introdução da ferramenta tox para gerenciamento de ambientes de teste.



Commit 6d336c1






 **aksg87** committed on Jul 18, 2025 · ✓ 2/2


ci(LangExtract): Add workflow for linting and tests


Adds a GitHub Actions CI workflow to run linting and tests against Python 3.10 and 3.11.

- Introduces 'tox' for managing test environments.
- Updates 'pyproject.toml' to require Python 3.10+ and add 'tox' as a development dependency.
- Excludes docs, tests, and other non-essential files from the distributable package via 'pyproject.toml'.

 **main** ·  v1.1.1 ... v1.0.0

- ▼ .github/workflows
 -  ci.yaml
-  .pylintrc
-  README.md
-  pyproject.toml
-  tox.ini


 **5 files changed** +116 -4 lines changed

▼ .github/workflows/ci.yaml 

... @@ -0,0 +1,47 @@

1 + # Copyright 2025 Google LLC.

2 + #

3  + # Licensed under the Apache License, Version 2.0 (the "Li

4 + # you may not use this file except in compliance with the

5 + # You may obtain a copy of the license at

6 + #

7 + # <http://www.apache.org/licenses/LICENSE-2.0>

8 + #

9 + # Unless required by applicable law or agreed to in writi

10 + # distributed under the License is distributed on an "AS

11 + # WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either ex

12 + # See the License for the specific language governing per

13 + # limitations under the License.

14 +

15 + name: CI

16 +

17 + on:

18 + push:

19 + branches: ["main"]

20 + pull_request:

21 + branches: ["main"]

22 +

23 + permissions:

24 + contents: read

25 +

26 + jobs:

27 + test:

Além disso, a aba *Actions* do GitHub apresenta um histórico consistente de execuções dos workflows, indicando que os pipelines estão ativos e em uso contínuo.

The screenshot shows the GitHub Actions interface for the repository `google/langextract`. The 'All workflows' tab is selected, displaying a list of workflow runs. The left sidebar shows the 'Actions' section with various workflow categories. The main area shows a table of workflow runs with columns for Event, Status, Branch, and Actor. The table lists several successful runs for 'Auto Update PR' and 'feat(gemini): add thinking_config to handled_keys support Gemini 2.0'.

Event	Status	Branch	Actor
Auto Update PR #256: Scheduled	Success	main	GitHub Actions
Auto Update PR #255: Scheduled	Success	main	GitHub Actions
Auto Update PR #254: Scheduled	Success	main	GitHub Actions
Auto Update PR #253: Scheduled	Success	main	GitHub Actions
CI #579: Pull request #326 synchronize by Eatosin	Success	main	Eatosin
Check PR Up-to-Date #279: Pull request #326 synchronize by Eatosin	Success	main	Eatosin
Protect Infrastructure Files #524: Pull request #326 synchronize by Eatosin	Success	main	Eatosin
Require linked issue with community support #403: Pull request #326 synchronize by Eatosin	Success	main	Eatosin
Validate PR template #552: Pull request #326 synchronize by Eatosin	Success	main	Eatosin
Check PR size #336: Pull request #326 synchronize by Eatosin	Success	main	Eatosin

No histórico de Pull Requests, é possível observar a presença de *status checks* ❌ ou ✅, que informam aos revisores se as verificações automatizadas foram concluídas com sucesso ou falha antes da integração do código.

The screenshot shows the GitHub Pull Requests interface for the repository `google/langextract`. The 'Pull requests' tab is selected, displaying a list of pull requests. The left sidebar shows the 'Pull requests' section with various filters. The main area shows a table of pull requests with columns for Title, Author, Labels, Projects, Milestones, Reviews, Assignees, and Sort. The table lists several pull requests, including 'feat(gemini): add thinking_config to handled_keys support Gemini 2.0' and 'Use shields.io for DOI badge to avoid Zenodo badge timeouts'.

Title	Author	Labels	Projects	Milestones	Reviews	Assignees	Sort
feat(gemini): add thinking_config to handled_keys support Gemini 2.0	Eatosin	enhancement			1		
Use shields.io for DOI badge to avoid Zenodo badge timeouts	Eatosin	bug			1		
Prevent semantic template collapse in VSA integration	Eatosin	bug			1		
docs: Fix typo and improve professionalism in README.md	Eatosin	documentation			1		
Fix: Configure Dependabot for GitHub Actions updates	Eatosin	bug			1		
Fix: Unpack and store alignment parameters in Resolver	Eatosin	bug			1		
Add edge case tests for prompt validation	Eatosin	bug			1		
forktest	Eatosin	bug			1		
Add Grog provider using OpenAI-compatible API	Eatosin	bug			1		
feat: Add cross-chunk context awareness for conference resolution	Eatosin	enhancement			1		
[Security] Fix CRITICAL vulnerability: V-002	Eatosin	security			1		
[Security] Fix CRITICAL vulnerability: V-001	Eatosin	security			1		
docs: Clarify best practices for few-shot examples	Eatosin	documentation			1		
fix: Handle non-Gemini model output parsing edge cases	Eatosin	bug			1		
fix: Handle non-Gemini model output parsing edge cases	Eatosin	bug			1		
Feature/migrate to uv	Eatosin	enhancement			1		
chore: Bump version to 1.1.1	Eatosin	bug			1		
Fix: Pass project parameter correctly to storage.Client in Gemini Batch API	Eatosin	bug			1		
refactor: Multi language tokenizer support (Unicode & Regex)	Eatosin	enhancement			1		

Essas evidências confirmam que o projeto possui automação funcional e integrada ao processo de colaboração.

6. FLUXO ATUAL

Com base na análise realizada, o fluxo atual de desenvolvimento do projeto pode ser descrito da seguinte forma:

- Criação de alterações no código-fonte
 - Os contribuidores realizam modificações no código localmente e submetem essas alterações ao repositório por meio de commits.
- Abertura de Pull Requests (PRs)
 - As mudanças são integradas ao fluxo principal do projeto através da abertura de Pull Requests no GitHub, permitindo revisão por outros colaboradores ou mantenedores.
- Execução automática dos workflows de CI
 - Ao ocorrer um evento de *push* ou a abertura/atualização de um Pull Request, os workflows definidos no diretório [.github/workflows/](#) são acionados automaticamente pelo GitHub Actions.
- Feedback automatizado
 - Os resultados das execuções são exibidos diretamente no Pull Request por meio de *status checks* visuais (sucesso ou falha). Esse feedback imediato informa se o código atende aos critérios mínimos de qualidade antes da revisão humana.
- Revisão e integração do código
 - Apenas após a conclusão bem-sucedida das verificações automatizadas, o Pull Request pode ser revisado e, eventualmente, aprovado e mesclado ao branch principal do projeto.

7. CONCLUSÃO

A análise do projeto LangExtract demonstra um nível consistente de maturidade no uso de práticas de Integração Contínua. A adoção do GitHub Actions como ferramenta de CI, aliada à execução automatizada de linting e testes em múltiplas versões do Python, contribui diretamente para a manutenção da qualidade do código e para a detecção precoce de erros.

A presença de pipelines ativos e integrados ao fluxo de Pull Requests evidencia uma preocupação com a estabilidade do projeto e com a prevenção de regressões, fatores essenciais para a evolução sustentável do software. Além disso, o feedback automatizado fornecido pelas execuções de CI facilita a entrada de novos contribuidores, pois estabelece critérios claros e objetivos para a aceitação de mudanças.

Dessa forma, conclui-se que o LangExtract possui um processo de desenvolvimento bem estruturado no que se refere à Integração Contínua, reduzindo gargalos manuais e fortalecendo a confiabilidade do projeto ao longo de seu ciclo de vida.